



Universität
Marburg

Sitzung 9: Paradigmenwechsel: Inferenz vs. Prädiktion

Dr. Philipp Bierwirth

Differentielle Psychologie und Persönlichkeitsforschung

SoSe 2026



Universität
Marburg



Lerntagebuchabgabe

15.09.2026




Inhalt

- 1) Rückblick
- 2) Darstellung von Effekten: Inferenz & Prädiktion
- 3) Ausgewählte Leistungs-Metriken im *Machine Learning* (statistischem Lernen)
- 4) Kombination von Merkmalen (multivariat)



Rückblick





Universität
Marburg

1. Darstellung von Effekten: Inferenz und Prädiktion




Darstellung von Zwischensubjekteffekten: Prädiktion vs. Inferenz

- Prädiktion (A-C) bezieht sich auf Klassifizierbarkeit:
 - Können wir alleine aufgrund des Messwertes vorhersagen, aus welcher Gruppe eine Beobachtung stammt
 - Aleatorische Ungewissheit
- Inferenz (D) bezieht sich v.a. auf statistische Signifikanz:
 - z.B. unterscheiden sich die Mittelwerte zwischen zwei Gruppen
 - Hängt davon ab, wie präzise man die Mittelwerte schätzen kann
 - Epistemische Ungewissheit


(A)

Beeswarm-Plot (Unabhängige Daten)




(B)

Box-Plot (Unabhängige Daten)




(C)

Violin-Plot (Unabhängige Daten)



(D)




Balkendiagramm mit Standardfehler





Darstellung von Innersubjekteffekten: Prädiktion vs. Inferenz

- Zwischensubjektvarianz kann sehr starke Innersubjekteffekte visuell völlig verschleiern (A)
- Wichtig ist hier die gepaarte Differenz innerhalb eines jeden Probanden (B-C)
- Gepaarte Differenz bestimmt Effektstärke (B-C) und damit auch Prädiktionskraft






Universität
Marburg

2. Ausgewählte Leistungs-Metriken im *Machine Learning (statistischem Lernen)*



Gruppenunterschiede in einem Merkmal


Wir erfassen ein Merkmal in zwei Gruppen.



Können wir das Merkmal nutzen, um die Beobachtungen einer der beiden Gruppen zuzuordnen?



Gruppenunterschiede in einem Merkmal




“Model”: wenn Merkmal $>$ co dann Klassifikation als krank, wenn nicht als gesund

Klassifikationsleistung über Vergleich der klassifizierten Gruppe mit tatsächlicher Gruppenzugehörigkeit



Gruppenunterschiede in einem Merkmal




	Krank	Gesund	Test N=
Merkmal $>$ co	6	0	+ = 6
Merkmal $<$ co	0	6	- = 6
N=	6	6	

“Konfusionsmatrix”



Gruppenunterschiede in einem Merkmal




	Krank	Gesund	Test N=
Merkmal $>$ co	4	2	$+ = 6$
Merkmal $<$ co	2	4	$- = 6$
N=	6	6	

“Konfusionsmatrix”



Gruppenunterschiede in einem Merkmal



	Krank	Gesund	Test N=
Merkmal > co	4 (TP)	2 (FP)	+ = 6
Merkmal < co	2 (FN)	4 (TN)	- = 6
N=	6	6	

“Konfusionsmatrix”



Konfusionsmatrix

	Krank	Gesund	Test n=
Merkmal > co	4 (TP)	2 (FP)	+ = 6
Merkmal < co	2 (FN)	4 (TN)	- = 6
n=	n = 6	n = 6	N = 12

Quantifizierung der Klassifikationsleistung über die Akkuratheit:

Wie viel Prozent all meiner Vorhersagen waren insgesamt richtig?

$$\text{Akkuratheit} = \frac{(TP + TN)}{N}$$

$$\text{Akkuratheit} = \frac{(4 + 4)}{12} = 0.67$$

Wenn wir raten würden, lege
die Akkuratheit in unserem
Beispiel bei 0.5



Konfusionsmatrix

	Krank	Gesund	Test n=
Merkmal > co	4 (TP)	2 (FP)	+ = 6
Merkmal < co	2 (FN)	4 (TN)	- = 6
n=	n = 6	n = 6	N = 12

Quantifizierung der Klassifikationsleistung über die Sensitivität:

Wie viel Prozent aller Kranken hat mein Test als krank klassifiziert?

$$\text{Sensitivität} = \frac{TP}{(TP + FN)}$$

$$\text{Sensitivität} = \frac{4}{6} = 0.67$$



Konfusionsmatrix

	Krank	Gesund	Test n=
Merkmal > co	4 (TP)	2 (FP)	+ = 6
Merkmal < co	2 (FN)	4 (TN)	- = 6
n=	n = 6	n = 6	N = 12

Quantifizierung der Klassifikationsleistung über die Sensitivität:


Wie viel Prozent aller Gesunden hat mein Test als gesund klassifiziert?

$$\text{Spezifität} = \frac{TN}{(FP + TN)}$$

$$\text{Spezifität} = \frac{4}{6} = 0.67$$



Gruppenunterschiede in einem Merkmal



Erstellen Sie eine Konfusionsmatrix für das obige Beispiel und berechnen Sie die Akkuratheit, Sensitivität und Spezifität



**Universität
Marburg**



Gruppenunterschiede in einem Merkmal

Problem:

- Bei unbalancierten Gruppen ist es leicht, ein Modell zu generieren, das eine hohe Akkuratheit besitzt.
- Wenn eine Krankheit eine sehr geringe Prävalenz hat ($<1\%$), können wir einfach alle Beobachtungen als gesund klassifizieren und wir erhalten eine Akkuratheit von über 99%


Potentielle Lösungen:

- Balancierte Akkuratheit
- Area Under the Curve (AUC)



Balancierte Akkuratheit

$$\frac{1}{N} \times \sum_{\text{Gruppe}_i}^N \frac{(TP_i + TN_i)}{n_i}$$



In unserem Beispiel....

Wir berechnen den Summanden separat in der Gruppe der Gesunden und Kranken:

$$TP = 0; TN = 11; n = 11$$

$$TP = 0; TN = 0; n = 1$$

$$\frac{(0+11)}{11} = 1$$

$$\frac{(0+0)}{1} = 0$$



Balancierte Akkuratheit

$$\frac{1}{N} \times \sum_{\text{Gruppe}_i}^N \frac{(TP_i + TN_i)}{n_i}$$


i = gesund i = krank

$$\frac{(0+11)}{11} = 1$$
$$\frac{(0+0)}{1} = 0$$
$$\frac{1}{2} \times (1+0) = 0.5$$

Anstatt einer Akkuratheit von ~0.92, erhalten wir eine balancierte Akkuratheit von 0.5. Unser "Modell" ist also eigentlich nicht besser als Raten.



Area Under the Curve



Der cut off kann prinzipiell arbiträr festgelegt werden

Allerdings geht jeder cut-off mit unterschiedlichen Sensitivitäten und Spezifitäten einher


Die AUC basiert auf der Berechnung der Sensitivität und Spezifität jedes möglichen Cut-Offs



Area Under the Curve



Receiver Operating Characteristic Curve (ROC):



Wahrscheinlichkeit,
dass eine zufällige
Beobachtung aus
Gruppe 2 größer ist
als eine zufällige
Beobachtung aus
Gruppe 1



Erwartbare Effektstärkens in der Psychologie (interindividuelle Differenzen)

25 %-Perzentil bei $d \sim 0.2$ ($r = 0.1$)

- AUC ~ 0.56

50 %-Perzentil bei $d \sim 0.4$ ($r = 0.2$)

- AUC ~ 0.61

75 %-Perzentil bei $d \sim 0.6$ ($r = 0.3$)

- AUC ~ 0.66




Fig. 1. Histogram of meta-analytically derived correlations (r).

Gignac & Szodorai (2016)





Universität
Marburg

3. Kombination von Merkmalen (multivariat)



Kombination von Merkmalen

Illustration: Wir haben zwei Merkmale, die sich minimal zwischen den Gruppen unterscheiden:






Kombination von Merkmalen

Linearer Klassifikator findet Ebene (im 2d-Fall eine Linie), welche die Gruppen optimal trennt.
z.B.:

- Logistische Regression
- Support Vektor Maschine
- Neuronales Netzwerk
- Lineare Diskriminanzanalyse
- etc.

Multivariate Betrachtung



$$\beta_0 + \beta_1 \times x_1 + \beta_2 \times x_2$$

- x = Merkmale
- β = Classifier-Gewichte

